

# TIỂU LUẬN MÔN HỌC

## THỊ GIÁC MÁY TÍNH VÀ ỨNG DỤNG

ỨNG DỤNG MÁY VECTƠ HỖ TRỢ (SVM) TRONG PHÂN LOẠI RÁC THẢI:  
NHỰA VÀ KIM LOẠI

Ngành: ROBOT và Trí Tuệ Nhân Tạo

Lớp: 22DRTA1

**GIẢNG VIÊN : TS. PHẠM QUỐC THIỆN**

**Sinh viên thực hiện:**

**MSSV:**

**Lớp:**

Nguyễn Chấn Huy

2286300020

22DRTA1

*TP. Hồ Chí Minh, ngày 3 tháng 4 năm 2025*

## Mục lục

<b>RUBRIC đánh giá môn học.....</b>	<b>0</b>
<b>Tóm tắt.....</b>	<b>3</b>
<b>1.Tổng quan đề tài.....</b>	<b>3</b>
<b>1.1 Giới thiệu.....</b>	<b>3</b>
<b>1.2 Lý do chọn đề tài.....</b>	<b>4</b>
<b>1.3 Lý do chọn SVM( Support machine learning).....</b>	<b>4</b>
<b>1.4 Mục tiêu của đề tài.....</b>	<b>5</b>
<b>1.5 Ứng dụng thực tiễn.....</b>	<b>5</b>
<b>2. Tổng quan về Support Vector Machine (SVM).....</b>	<b>6</b>
<b>2.1. Nguyên lý hoạt động.....</b>	<b>6</b>
<b>2.2. cơ sở lý thuyết.....</b>	<b>6</b>
<b>2.3. Tham số quan trọng trong SVM.....</b>	<b>8</b>
<b>3. Dữ liệu và Tiền xử lý.....</b>	<b>9</b>
<b>3.1. Tập dữ liệu.....</b>	<b>9</b>
<b>3.2. Tiền xử lý dữ liệu.....</b>	<b>10</b>
<b>4. Huấn luyện mô hình SVM.....</b>	<b>10</b>
<b>5. Đánh giá mô hình.....</b>	<b>12</b>
<b>5.1. Độ chính xác.....</b>	<b>12</b>

<b>5.2. Ma trận nhầm lẫn.....</b>	<b>14</b>
<b>5.3. Hình ảnh bị phân loại sai.....</b>	<b>15</b>
<b>5.3.1. Hình ảnh phân loại sai.....</b>	<b>15</b>
<b>5.3.2. Cách khắc phục .....</b>	<b>16</b>
<b>5.4. Biểu đồ phân bố dữ liệu.....</b>	<b>16</b>
<b>5.5 So sánh các kernel.....</b>	<b>17</b>
<b>5.5.1. Biểu đồ thể hiện điều gì?.....</b>	<b>17</b>
<b>5.5.2. Phân tích kết quả.....</b>	<b>18</b>
<b>5.5.3. Tại sao RBF lại tốt nhất?.....</b>	<b>22</b>
<b>5.5.4. Tại sao Linear lại kém?.....</b>	<b>22</b>
<b>5.5.5. Có nên chọn RBF luôn không?.....</b>	<b>22</b>
<b>5.5.6 Kết luận .....</b>	<b>23</b>
<b>6. Cải thiện mô hình.....</b>	<b>24</b>
<b>7. Kết luận.....</b>	<b>24</b>
<b>8. Tài liệu tham khảo.....</b>	<b>25</b>

# **ỨNG DỤNG MÁY VECTƠ HỖ TRỢ (SVM) TRONG PHÂN LOẠI RÁC THẢI: NHỰA VÀ KIM LOẠI**

## **Tóm tắt**

Bài tiểu luận nghiên cứu ứng dụng Máy Vectơ Hỗ Trợ (SVM) trong việc phân loại rác thải nhựa và kim loại, nhằm cải thiện hiệu quả trong quá trình phân loại và tái chế. SVM, với khả năng tìm kiếm siêu phẳng tối ưu, đã được ứng dụng để phân loại hình ảnh rác thải dựa trên các đặc trưng trích xuất từ phương pháp Histogram of Oriented Gradients (HOG). Dữ liệu huấn luyện bao gồm 2000 hình ảnh chai nhựa và lon kim loại, được tiền xử lý và chuẩn hóa để cải thiện hiệu suất mô hình. Sau khi thử nghiệm các tham số, mô hình đạt độ chính xác cao, lên tới 97,38% trên tập kiểm tra. Tuy nhiên, một số hình ảnh vẫn bị phân loại sai do nhiễu và ánh sáng không đồng đều. Bài viết cũng đề xuất các biện pháp cải thiện như điều chỉnh kích thước ảnh, bổ sung dữ liệu huấn luyện và áp dụng các kỹ thuật trích xuất đặc trưng mạnh mẽ hơn. Việc ứng dụng AI và học máy trong phân loại rác thải có thể giúp tự động hóa quy trình xử lý và đóng góp vào việc bảo vệ môi trường.

## **1. Tổng quan về đề tài**

### **1.1 Giới thiệu**

Trong thời đại công nghệ 4.0, việc xử lý rác thải thông minh trở thành một vấn đề bắt thiết nhằm giảm thiểu tác động tiêu cực lên môi trường. Các phương pháp truyền thống trong việc phân loại rác thải dựa vào lao động thủ công thường kém hiệu quả và tốn nhiều tài nguyên. Nhờ vào sự tiến bộ của trí tuệ nhân tạo (AI) và học máy, chúng ta có thể xây dựng các hệ thống tự động nhận diện và phân loại rác thải một cách chính xác.

Một trong những phương pháp hiệu quả trong bài toán phân loại hình ảnh là Máy Vector Hỗ Trợ (Support Vector Machine - SVM). Trong bài viết này, chúng tôi sẽ trình bày về nguyên lý hoạt động của SVM và cách ứng dụng nó để phân loại rác thải nhựa (plastic) và kim loại (metal), nhằm đảm bảo việc xử lý rác hiệu quả hơn.

## 1.2 Lý do chọn đề tài

Trong bối cảnh ô nhiễm môi trường ngày càng gia tăng, việc phân loại rác thải một cách hiệu quả đóng vai trò quan trọng trong quá trình tái chế và xử lý chất thải. Tuy nhiên, các phương pháp phân loại truyền thống chủ yếu dựa vào sức lao động con người, tốn nhiều thời gian và có độ chính xác không cao. Do đó, ứng dụng trí tuệ nhân tạo (AI) và học máy (Machine Learning) trong việc tự động hóa quy trình phân loại rác là một giải pháp tiềm năng giúp nâng cao hiệu quả và giảm thiểu tác động tiêu cực đến môi trường.

Trong số các thuật toán học máy, Máy Vector Hỗ Trợ (SVM) đã chứng minh tính hiệu quả trong nhiều bài toán phân loại, đặc biệt là trong nhận dạng hình ảnh. Nhờ vào khả năng tìm kiếm một siêu phẳng tối ưu để phân tách dữ liệu, SVM có thể đạt được độ chính xác cao ngay cả khi tập dữ liệu có kích thước nhỏ và có sự chồng lấn giữa các lớp. Điều này đặc biệt hữu ích trong bài toán phân loại rác thải nhựa và kim loại, nơi mà hình dạng và đặc trưng bề mặt có thể gây khó khăn cho các phương pháp truyền thống.

Với những lý do trên, đề tài **“Ứng dụng Máy Vector Hỗ Trợ (SVM) trong phân loại rác thải: Nhựa và Kim loại”** được lựa chọn nhằm nghiên cứu và phát triển một mô hình tự động, góp phần nâng cao hiệu quả phân loại rác, hỗ trợ quá trình tái chế, và hướng đến mục tiêu bảo vệ môi trường bền vững.

## 1.3 Lý do chọn SVM( Support machine learning)

SVM (Support Vector Machine) là một lựa chọn phù hợp cho bài toán phân loại rác thải nhờ vào nhiều ưu điểm vượt trội. Trước tiên, SVM hoạt động hiệu quả ngay cả khi số lượng dữ liệu huấn luyện hạn chế, điều này rất hữu ích trong trường hợp dữ liệu ảnh rác thải khó thu thập. Ngoài ra, mô hình có khả năng xử lý dữ liệu không tuyến tính thông qua các hàm kernel, giúp phân loại chính xác hơn khi rác thải có hình dạng, màu sắc và kích thước đa dạng. Một lợi thế quan trọng khác là SVM có khả năng chống nhiễu tốt nhờ tối ưu hóa khoảng cách

giữa các điểm dữ liệu biên (support vectors), giúp giảm tác động của các yếu tố như ánh sáng và bóng đổ. Hơn nữa, mô hình tối ưu hóa khoảng cách giữa các lớp bằng cách tìm kiếm siêu phẳng phân tách tốt nhất, giúp phân loại chính xác hơn so với các phương pháp như k-NN hoặc Naive Bayes. Một điểm mạnh khác của SVM là khả năng tránh overfitting nhờ vào kỹ thuật Regularization, chỉ tập trung vào các support vectors quan trọng. So với các mô hình deep learning như CNN, SVM có hiệu suất tính toán cao hơn, không đòi hỏi tài nguyên lớn nhưng vẫn đảm bảo độ chính xác cao, giúp tiết kiệm thời gian và chi phí triển khai. Ngoài ra, SVM không chỉ áp dụng cho phân loại nhị phân mà còn có thể mở rộng thành mô hình đa lớp bằng phương pháp One-vs-One hoặc One-vs-All để phân loại nhiều loại rác thải khác nhau. Nhờ vào những ưu điểm này, SVM trở thành một phương pháp hiệu quả, chính xác và tiết kiệm tài nguyên cho bài toán phân loại rác thải.

#### **1.4 Mục tiêu của đề tài**

Mục tiêu của đề tài là xây dựng một mô hình phân loại rác thải nhựa và kim loại dựa trên phương pháp Máy Vectơ Hỗ Trợ (SVM), nhằm hỗ trợ quá trình phân loại rác một cách tự động và chính xác. Đề tài tập trung vào việc trích xuất đặc trưng từ hình ảnh rác thải bằng phương pháp Histogram of Oriented Gradients (HOG) và thử nghiệm các tham số của SVM để tối ưu độ chính xác. Bên cạnh đó, nghiên cứu cũng đề xuất các kỹ thuật tiền xử lý hình ảnh và mở rộng dữ liệu nhằm cải thiện hiệu suất phân loại. Kết quả của đề tài có thể ứng dụng trong các hệ thống phân loại rác thông minh, góp phần nâng cao hiệu quả tái chế và bảo vệ môi trường.

#### **1.5 Ứng dụng thực tiễn**

SVM (Support Vector Machine) có nhiều ứng dụng thực tiễn trong việc phân loại rác thải, đặc biệt là trong các hệ thống quản lý và xử lý rác thải thông minh. Một trong những ứng dụng phổ biến là tích hợp SVM vào các hệ thống thu gom rác tự động, giúp nhận diện và phân loại rác ngay từ nguồn, giảm tải cho các công đoạn xử lý sau này. Các trạm thu gom rác thông minh có thể sử dụng camera và SVM để xác định loại rác (như nhựa, kim loại, giấy, thủy tinh, bìa cứng, rác thải thông thường), từ đó hướng dẫn người dùng bỏ rác đúng chỗ hoặc tự động điều hướng rác đến khu vực xử lý phù hợp.

Ngoài ra, SVM còn được ứng dụng trong dây chuyền tái chế rác thải, giúp robot hoặc hệ thống băng chuyền tự động nhận diện và tách riêng các loại vật liệu có thể tái chế, nâng cao hiệu suất xử lý và giảm thiểu ô nhiễm môi trường. Trong các nhà máy xử lý rác, SVM có thể kết hợp với các cảm biến (như cảm biến quang học, cảm biến từ trường) để phân loại rác một cách chính xác hơn mà không cần sự can thiệp của con người.

Bên cạnh đó, SVM cũng có thể áp dụng trong các ứng dụng di động hoặc nền tảng IoT, nơi người dùng có thể chụp ảnh rác thải và hệ thống AI sẽ phân loại giúp họ, hỗ trợ quá trình phân loại rác tại hộ gia đình hoặc khu vực công cộng. Việc áp dụng SVM trong phân loại rác không chỉ giúp nâng cao hiệu quả tái chế mà còn góp phần bảo vệ môi trường và giảm thiểu rác thải không được xử lý đúng cách.

## **2. Tổng quan về Support Vector Machine (SVM)**

### **2.1. Nguyên lý hoạt động**

SVM là một thuật toán học máy có giám sát được sử dụng rộng rãi trong bài toán phân loại. Mục tiêu chính của SVM là tìm một siêu phẳng “hyperplane” tối ưu để phân tách hai lớp dữ liệu một cách rõ ràng nhất.

Siêu phẳng này được xác định sao cho khoảng cách tối thiểu “margin” giữa nó và các điểm gần nhất thuộc hai lớp là lớn nhất có thể. Các điểm gần siêu phẳng nhất được gọi là “support vectors”, và chính chúng đóng vai trò quyết định biên quyết định (decision boundary) của mô hình.

### **2.2 cơ sở lý thuyết**

Support Vector Machine (SVM) là một thuật toán học máy sử dụng phương pháp tìm kiếm một siêu phẳng (hyperplane) tối ưu để phân loại dữ liệu. Siêu phẳng này giúp phân tách các nhóm dữ liệu sao cho khoảng cách giữa nó và các điểm dữ liệu gần nhất của mỗi lớp là lớn nhất. Điều này giúp mô hình có khả năng phân loại chính xác dữ liệu mới và tổng quát hóa tốt hơn.

Trong không gian nhiều chiều, siêu phẳng có vai trò như một ranh giới phân loại, với số chiều nhỏ hơn không gian dữ liệu một đơn vị. Cụ thể, trong không gian hai chiều, siêu phẳng là một đường thẳng, trong không gian ba chiều, nó là một mặt phẳng, và trong không gian  $n$  chiều, nó có  $n-1$  chiều.

SVM tìm kiếm siêu phẳng tối ưu bằng cách giải bài toán tối ưu hóa dựa trên phương trình tổng quát:

$$w \cdot x + b = 0$$

trong đó,  $w$  là vector trọng số,  $x$  là vector đặc trưng của dữ liệu, và  $b$  là độ lệch.

Bên cạnh việc xác định siêu phẳng phân loại, SVM còn tối đa hóa khoảng cách giữa nó và các điểm dữ liệu gần nhất (còn gọi là **support vectors**). Khi dữ liệu có thể phân tách tuyến tính, SVM sẽ tìm được siêu phẳng tối ưu với **margin** lớn nhất mà không để bất kỳ điểm dữ liệu nào nằm sai vị trí. Tuy nhiên, trong thực tế, dữ liệu thường không thể phân tách tuyến tính hoàn toàn, và SVM phải sử dụng **kernel trick** để ánh xạ dữ liệu sang không gian có số chiều cao hơn, nơi nó có thể phân tách tuyến tính.

Một số hàm kernel phổ biến trong SVM bao gồm:

- **Linear kernel:** Phù hợp với dữ liệu có thể phân tách tuyến tính, sử dụng công thức:

$$K(x, x') = x^T x'$$

- **Polynomial kernel:** Mở rộng khả năng phân loại với các quan hệ bậc cao, công thức:

$$K(x, x') = (x^T x' + c)^d$$

với  $c$  là hằng số và  $d$  là bậc của đa thức.

- **RBF (Radial Basis Function) kernel:** Sử dụng phân bố Gaussian để

$$K(x, x') = \exp(-\gamma \|x - x'\|^2)$$

phân loại dữ liệu phi tuyến tính:



Trong đó,  $\gamma$  kiểm soát mức độ ảnh hưởng của một điểm dữ liệu lên mô hình.

Khi dữ liệu chứa nhiều hoặc điểm ngoại lai, SVM sử dụng **soft margin** để cho phép một số điểm dữ liệu nằm trong vùng margin hoặc bị phân loại sai. Tham số **C** điều chỉnh sự cân bằng giữa độ chính xác phân loại và khả năng tổng quát hóa của mô hình:

- **C lớn:** Giảm lỗi phân loại nhưng có thể gây overfitting.
- **C nhỏ:** Cho phép một số lỗi nhưng cải thiện khả năng tổng quát hóa.

SVM giải bài toán tối ưu bằng cách tối thiểu hóa:

$$\frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \xi_i = \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \xi_i$$

trong đó  $\xi$  là biến trễ thể hiện mức độ vi phạm margin.

Một trong những hàm mất mát phổ biến của SVM là **Hinge Loss**, được định nghĩa là:

$$L = \max(0, 1 - y_i \cdot f(x))$$

trong đó,  $f(x) = w \cdot x + b$  là giá trị dự đoán, và  $y$  là nhãn thực tế.

SVM có thể được tối ưu hóa bằng các phương pháp như **Lagrangian multipliers** hoặc **SMO (Sequential Minimal Optimization)** để tìm ra giải pháp tối ưu một cách hiệu quả.

### 2.3. Tham số quan trọng trong SVM

**-Tham số C (Regularization Parameter):** Xác định mức độ đầu phạt đối với các điểm dữ liệu bị phân loại sai. Càng lớn C thì mô hình càng nghiêm khắc, nhưng dễ bị quá khớp (overfitting).

**-Tham số gamma:** Quy định tầm quan trọng của từng điểm dữ liệu trong việc xác định biên quyết định. Gamma cao giúp mô hình linh hoạt hơn, nhưng dễ gây quá khớp.

$$K(x_i, x_j) = \exp \left( -\frac{\|x_i - x_j\|^2}{2\sigma^2} \right)$$

**-Kernel:** Là hàm dùng để chế biến dữ liệu thành không gian cao hơn. Kernel RBF thường được sử dụng do khả năng phân loại linh hoạt. Được tính bằng công thức:

$$K(x,y) = e^{(-\gamma \|x-y\|^2)}$$

### 3. Dữ liệu và Tiền xử lý

#### 3.1. Tập dữ liệu

-Hình ảnh chai nhựa và lon lấy dữ liệu chụp được bằng điện thoại với lon và chai nhựa được sử dụng nhiều ở Việt Nam, để tiện cho việc thử nghiệm cho các dự án thực tế có thể phát triển trong tương lai. Tập dữ liệu được chia làm hai phần chính đó là tập chai nhựa(plastic) và tập kim loại(metal).

-Ở đề tài này số lượng chai nhựa(plastic) được sử dụng để huấn luyện gồm 2000 ảnh và được gắn nhãn tất cả. Tương tự tập kim loại(metal) dữ liệu được huấn luyện cũng tương đương với 2000 ảnh và được gắn nhãn cho từng bức ảnh. Dữ liệu ảnh để test được lấy từ 20% của tập ảnh train để thử nghiệm độ chính xác cho mô hình

-Tập dữ liệu bao gồm hình ảnh của rác thải nhựa và kim loại. Mỗi ảnh được gắn nhãn tương ứng:

- **Lớp 0:** Nhựa (plastic)
- **Lớp 1:** Kim loại (metal)

### 3.2. Tiền xử lý dữ liệu

-Các bước tiền xử lý bao gồm:

1. Chuyển đổi ảnh về mức xám để giảm kích thước dữ liệu.
2. Thay đổi kích thước ảnh thành 64x64 pixel để đảm bảo độ đồng nhất.
3. Áp dụng Gaussian Blur để giảm nhiễu.
4. Trích xuất đặc trưng bằng phương pháp HOG (Histogram of Oriented Gradients).
5. Chuẩn hóa dữ liệu bằng StandardScaler để đảm bảo hiệu suất mô hình cao nhất.

### 4. Huấn luyện mô hình SVM

-Sau khi chuẩn hóa dữ liệu, tập dữ liệu được chia thành:

- **Tập huấn luyện:** 80% dữ liệu(3200 ảnh)
- **Tập kiểm tra:** 20% dữ liệu(800 ảnh)

-Mô hình SVM được huấn luyện với kernel RBF,  $C=100$  và  $\gamma=75e-5$ . Sau khi huấn luyện, thời gian huấn luyện được ghi nhận để đánh giá hiệu suất mô hình.

-Quá trình tính tham số  $\gamma$ :

-Trong bài toán này, ảnh được resize về kích thước 64x64 pixels và chia thành các cell có kích thước 8x8 pixels.

-Số cell theo mỗi chiều của ảnh là:  $64/8=8$

- Tổng số cell trong ảnh là:  $8 \times 8 = 64$  cells

-Thay vì tính đặc trưng từ từng cell riêng lẻ, HOG nhóm cell thành các khối ("block") để cải thiện tính chống nhiễu và biến đổi độ sáng. Trong trường hợp này, mỗi block gồm 2x2 cells.

-Mỗi khối có  $2 \times 2 = 4$  cells, và chúng được trượt qua ảnh với bước nhảy là 1 cell. Do đó, số block theo chiều ngang và chiều dọc là:  $(8-2)/1 + 1 = 7$

Tổng số block trong ảnh là:  $7 \times 7 = 49$  blocks

-Mỗi cell sẽ được biểu diễn bằng một histogram có **9 bins**, mã hóa hướng gradient trong cell.

-Mỗi khối gồm  $2 \times 2$  cells, nên tổng số giá trị HOG trong mỗi block là:

$4\text{cells} \times 9\text{bins} = 36$  giá trị đặc trưng

-Vì mỗi block đóng góp 36 giá trị đặc trưng và ảnh chứa 49 blocks, tổng số đặc trưng HOG của ảnh là:  $49 \times 36 = 1764$  đặc trưng.

từ đó ta có thông số đặc trưng HOG sau đó điền vào công thức để tính gamma:

$$\gamma = 1/1764 = \mathbf{5.67e-5}$$

-Điền thông số gamma vào mô hình ra kết quả có thể chấp nhận được, nhưng nó chưa được tối ưu nhất: **94.38%**

-Sau đó ta thử sai trên nhiều thông số gamma khác nhau kể từ tập **5.67e-5**

trở lên cho đến khi tìm được thông số lý tưởng nhất, tham số lý tưởng sau khi thử sai trong mô hình này là **75e-5** kết quả chính xác cao nhất trong tập test từ **94.38%** lên đến **97.38%**

- Hiện biểu đồ số lượng 2 tập dữ liệu phân loại được đưa vào mô hình, sau đó huấn luyện mô hình và lấy 20% ảnh trong tập huấn luyện để kiểm tra độ chính xác của mô hình và hiện biểu đồ confusion matrix để đối chiếu thông số chính xác của 2 thành phần là bao nhiêu.

### Confusion matrix:

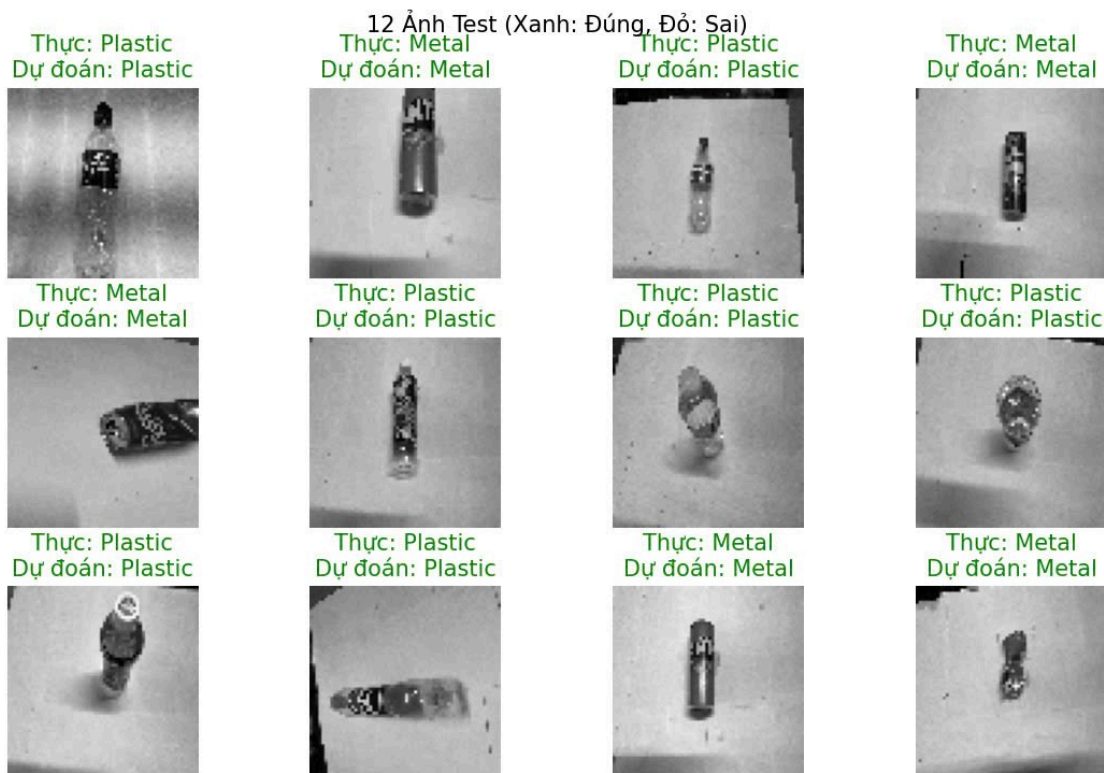
	precision	recall	f1-score	support
metal	0.99	0.96	0.97	422
plastic	0.96	0.99	0.97	378
accuracy			0.97	800
macro avg	0.97	0.97	0.97	800
weighted avg	0.97	0.97	0.97	800

## 5. Đánh giá mô hình

### 5.1. Độ chính xác

-Sau khi thử nghiệm và điều chỉnh các chỉ số C, gamma và thay đổi kích thước hợp lý và trích xuất đặc trưng mô hình đã đạt được độ chính xác trên tập test gần như hoàn hảo. Với hình ảnh nhận diện chính xác là 405 với plastic và 372 với metal. Tổng các hình ảnh đã bị nhầm lẫn là 23 ảnh, bao gồm ảnh của

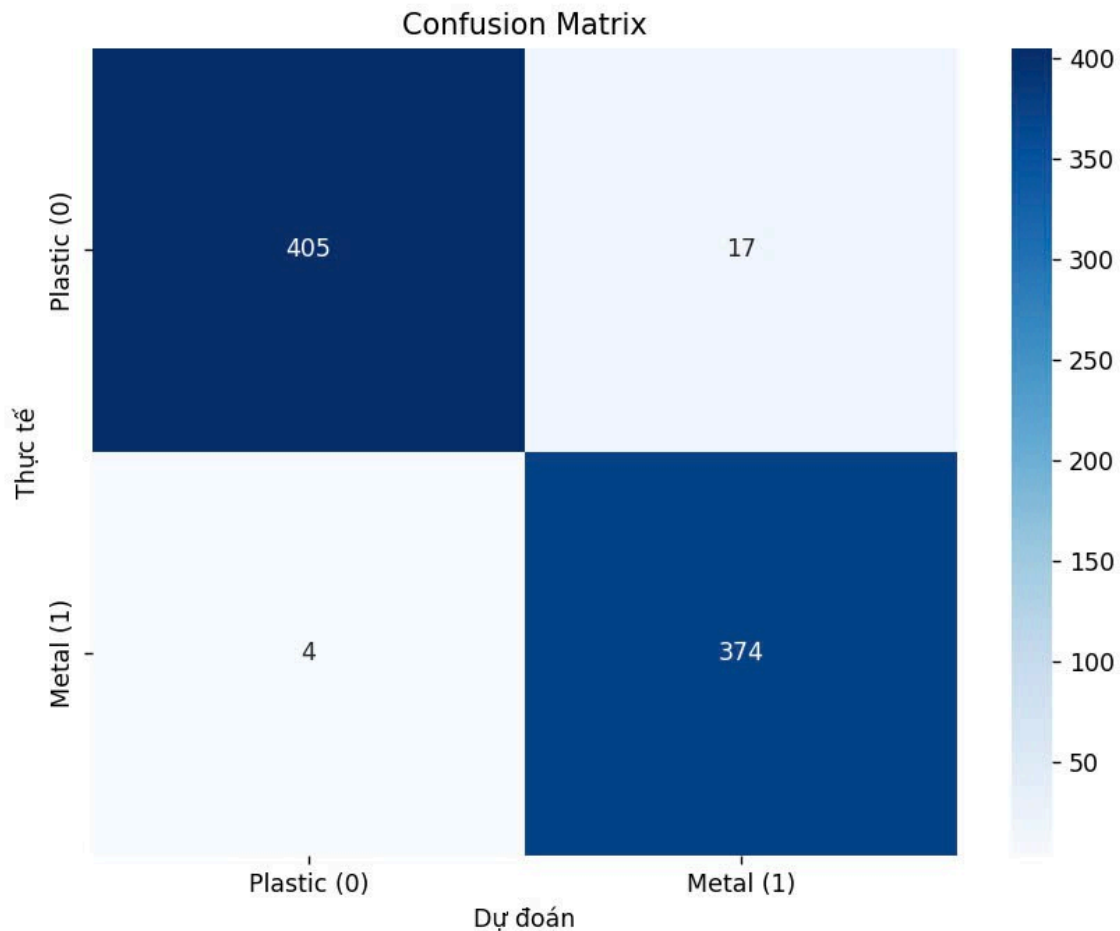
plastic va metal.



- Hình ảnh hiện ngẫu nhiên 12 ảnh trong tập kiểm tra để thử nghiệm độ chính xác của mô hình, như ta thấy hầu hết điều nhận diện chính xác. Mô hình đạt độ chính xác **97,38%** trên tập kiểm tra.

## 5.2. Ma trận nhầm lẫn

-Ma trận nhầm lẫn giúp đánh giá số lượng mẫu bị phân loại sai và đúng:



Thực tế	Dự đoán: Nhựa	Dự đoán: Kim loại
Nhựa	TP	FN
Kim loại	FP	TN

-TP (True Positive): Nhận diện đúng nhựa. FN (False Negative): Nhận diện nhựa thành kim loại. FP (False Positive): Nhận diện kim loại thành nhựa. TN (True Negative): Nhận diện đúng kim loại.

### 5.3. Hình ảnh bị phân loại sai

#### 5.3.1. Hình ảnh phân loại sai.

Tổng số ảnh bị nhận diện sai: 21

Thực: Plastic  
Dự đoán: Metal



Thực: Plastic  
Dự đoán: Metal



Thực: Plastic  
Dự đoán: Metal



Thực: Plastic  
Dự đoán: Metal



Thực: Plastic  
Dự đoán: Metal



Thực: Plastic  
Dự đoán: Metal



Thực: Plastic  
Dự đoán: Metal



Thực: Metal  
Dự đoán: Plastic



Thực: Plastic  
Dự đoán: Metal



Thực: Plastic  
Dự đoán: Metal



Thực: Plastic  
Dự đoán: Metal



Thực: Plastic  
Dự đoán: Metal



Thực: Plastic  
Dự đoán: Plastic



Thực: Metal  
Dự đoán: Plastic



Thực: Plastic  
Dự đoán: Metal



Thực: Plastic  
Dự đoán: Metal



Thực: Plastic  
Dự đoán: Metal



Thực: Metal  
Dự đoán: Plastic



Thực: Metal  
Dự đoán: Plastic






Thực: Plastic  
Dự đoán: Metal



Thực: Plastic  
Dự đoán: Metal



-đây là các hình ảnh bị nhận diện sai cụ thể là 23 bức ảnh, nguyên nhân có thể là do các bức ảnh bị nhiễu hoặc ánh sáng không đồng đều, ở đây ta có thể thấy trong hình có vài bức ảnh bị đổ bóng do máy ảnh, một phần là do kích thước của ảnh đã resize nhỏ nên vài chi tiết đã bị mất và bức ảnh không rõ chi tiết nên dễ bị nhầm lẫn.




*các hình ảnh bị lỗi do: mất chi tiết, ánh sáng không đều, không rõ các chi tiết, và bị bóng đổ*



### 5.3.2. Cách khắc phục


-để cải thiện độ chính xác của mô hình phân loại rác ra cần khắc phục và điều chỉnh các yếu tố như sau. Điều chỉnh kích thước hình ảnh lớn hơn chẳng hạn thay vì 64x64 ta thay đổi thành 128x128 hoặc bổ sung dữ liệu huấn luyện và có thể xóa các bức ảnh gây ảnh hưởng đến độ chính xác của mô hình.

### 5.4. Biểu đồ phân bố dữ liệu



-Đây là biểu đồ hiển thị quá trình thử sai của Gamma. Quá trình thử sai với giá trị ban đầu là **5,67e-5**, sau đó thử sai liên tục và đưa ra tham số lý tưởng nhất đó là **75e-5**, do tham số trên lệch giữa các số gần 75e-5 không nhỏ, nên những tham số trên biểu đồ lấy từ tham số tiêu chuẩn đã được tối ưu nhất làm mẫu và lấy 2 tham số ngẫu nhiên để đối chiếu sự chênh lệch. Từ biểu đồ này cho thấy sự thay đổi giữa tham số gamma liên quan đến độ chính xác của mô hình, và độ chính xác của mô hình trên tập huấn luyện cao nhất là **97,38%**.

## 5.5 So sánh các kernel



### 5.5.1. Biểu đồ thể hiện điều gì?

Biểu đồ này so sánh độ chính xác (accuracy) của mô hình SVM khi sử dụng các kernel khác nhau, bao gồm:

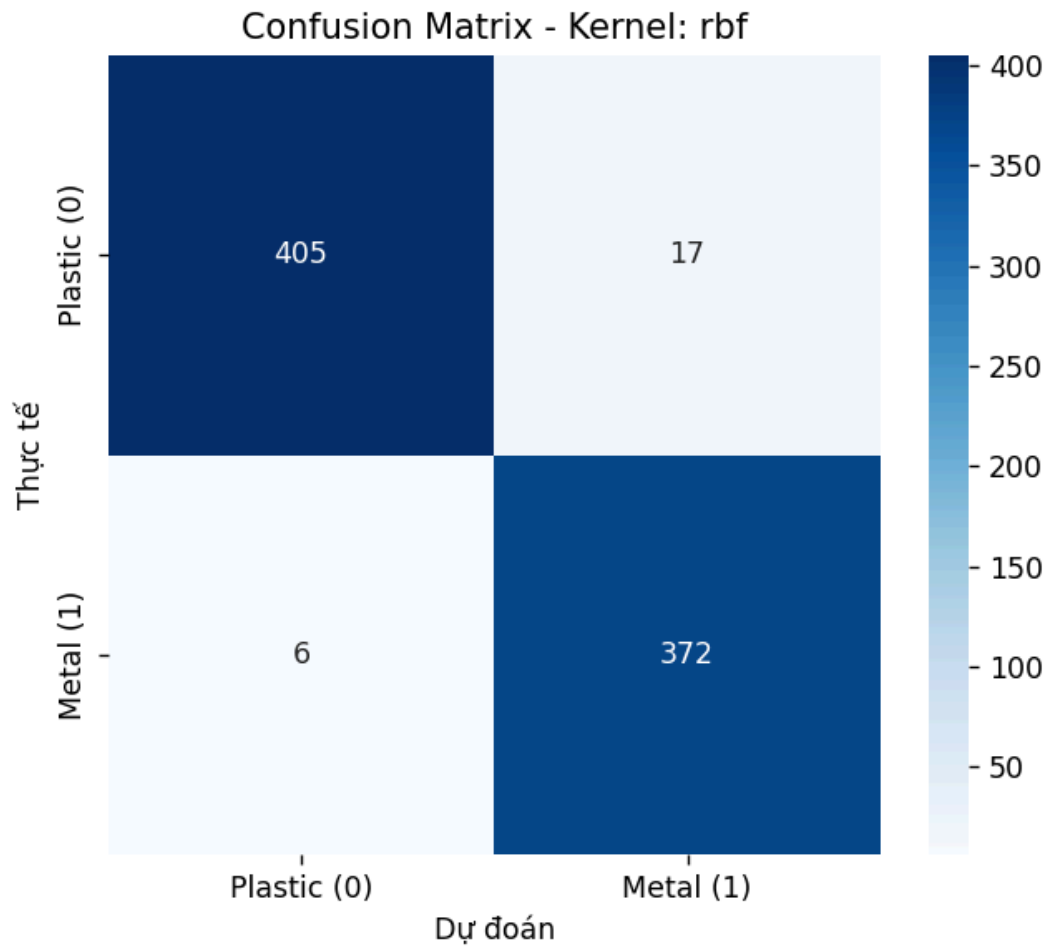
- Linear (Xanh dương): Kernel tuyến tính.
- Polynomial (Vàng): Kernel đa thức.
- RBF (Xanh lá cây): Kernel hàm Gaussian (Radial Basis Function).
- Sigmoid (Đỏ - không thấy trên biểu đồ): Kernel sigmoid.

Trục X đại diện cho loại kernel, còn trục Y thể hiện độ chính xác của mô hình trên tập kiểm tra (test set accuracy), được biểu diễn dưới dạng phần trăm.


### 5.5.2. Phân tích kết quả

Dựa vào biểu đồ:

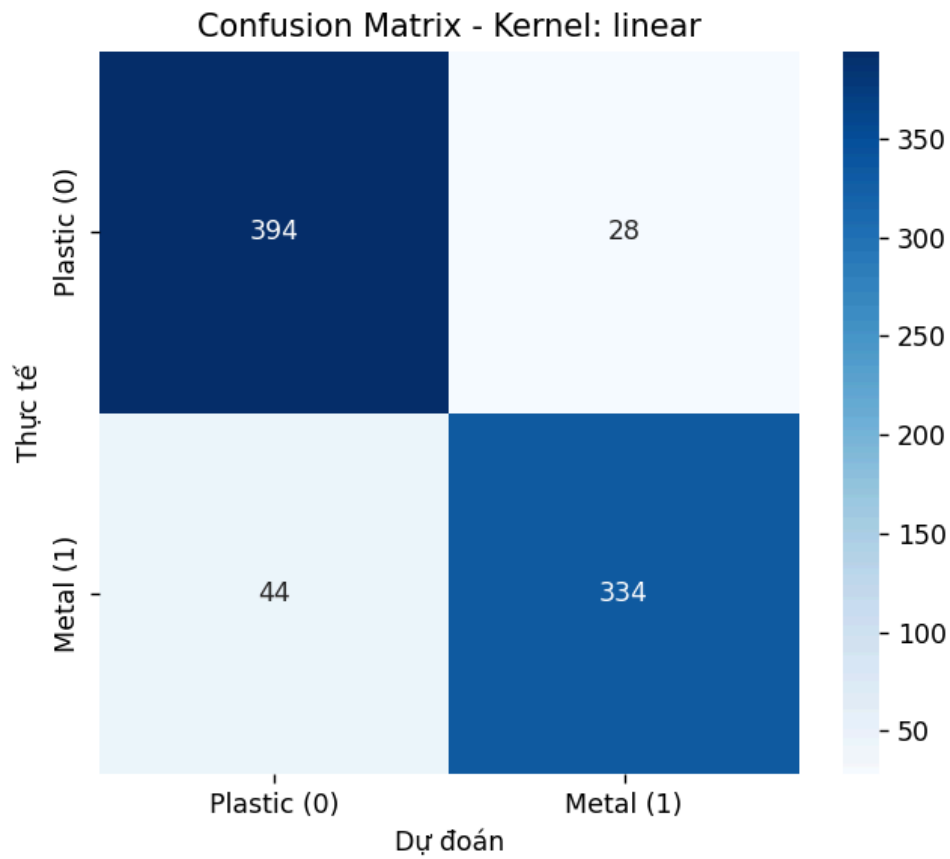
- Kernel RBF (Màu xanh lá cây) có độ chính xác cao nhất, khoảng 97%, cho thấy nó hoạt động tốt nhất trên tập dữ liệu này.



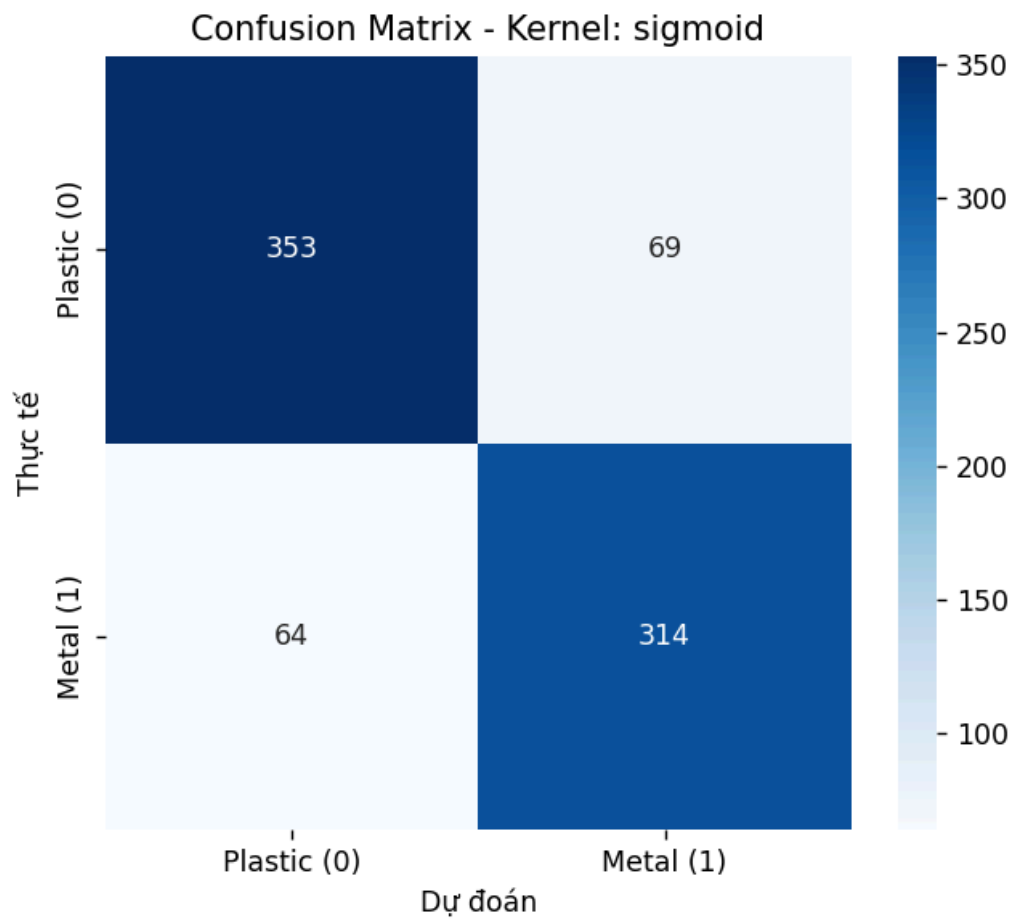
- Kernel Polynomial (Màu vàng) cũng đạt độ chính xác khá cao, khoảng 94%, nhưng vẫn thấp hơn RBF.



- Kernel Linear (Màu xanh dương) có độ chính xác thấp nhất, khoảng 91%, cho thấy dữ liệu không thể phân tách tuyến tính một cách tốt nhất.



- Kernel Sigmoid không xuất hiện trên biểu đồ, có thể do độ chính xác của nó quá thấp, không đáng kể so với các kernel khác.



### 5.5.3. Tại sao RBF lại tốt nhất?

- RBF Kernel hoạt động tốt với dữ liệu phi tuyến tính vì nó có thể tạo ra các đường quyết định phức tạp hơn bằng cách ánh xạ dữ liệu vào không gian có nhiều chiều hơn.
- Độ chính xác cao chứng tỏ dữ liệu có sự phân bố không tuyến tính và RBF có thể mô hình hóa tốt điều này.

### 5.5.4. Tại sao Linear lại kém?

- Linear Kernel chỉ hiệu quả khi dữ liệu có thể phân tách tuyến tính. Tuy nhiên, dữ liệu của bài toán phân loại rác có thể không phải là một bài toán tuyến tính, dẫn đến độ chính xác thấp.

### 5.5.5. Có nên chọn RBF luôn không?

- RBF là lựa chọn tốt nhất trong trường hợp này.
- Tuy nhiên, nếu muốn giảm chi phí tính toán, có thể thử Polynomial Kernel với degree thấp hoặc Linear Kernel nếu dữ liệu thực sự có thể phân tách tuyến tính.
- Sigmoid thường ít được sử dụng trong SVM vì nó hoạt động không ổn định và dễ bị overfitting.

### 5.5.6 Kết luận

- Kernel RBF là tốt nhất cho bài toán này vì nó đạt độ chính xác cao nhất.
- Kernel Linear có độ chính xác thấp, cho thấy dữ liệu không phân tách tuyến tính.
- Sigmoid có thể hoạt động không ổn định, vì vậy không xuất hiện trên biểu đồ.

#### Biểu đồ so sánh của các kernel:

Kernel	Ưu điểm	Nhược điểm
<b>Linear</b>	<ul style="list-style-type: none"><li>- Hiệu quả với dữ liệu phân tách tuyến tính.</li><li>- Tính toán nhanh hơn do đơn giản.</li></ul>	<ul style="list-style-type: none"><li>- Không phù hợp với dữ liệu phi tuyến.</li></ul>
<b>Polynomia</b>	<ul style="list-style-type: none"><li>- Xử lý dữ liệu phi tuyến tốt hơn linear.</li><li>- Có thể điều chỉnh độ phức tạp bằng tham số degree.</li></ul>	<ul style="list-style-type: none"><li>- Tốn nhiều tài nguyên khi degree cao.</li><li>- Dễ bị overfitting nếu degree quá lớn.</li></ul>
<b>RBF (Radial Basis Function)</b>	<ul style="list-style-type: none"><li>- Phù hợp với hầu hết các bài toán thực tế.</li><li>- Xử lý dữ liệu phi tuyến mạnh mẽ.</li></ul>	<ul style="list-style-type: none"><li>- Cần tinh chỉnh tham số gamma để tránh overfitting.</li><li>- Tính toán nặng hơn linear kernel.</li></ul>
<b>Sigmoid</b>	<ul style="list-style-type: none"><li>- Có thể hoạt động như một mạng nơ-ron đơn giản.</li></ul>	<ul style="list-style-type: none"><li>- Thường không ổn định trong nhiều bài toán phân loại.</li><li>- Kém hiệu quả hơn RBF trong hầu hết các trường hợp.</li></ul>



## 6. Cải thiện mô hình

-Để cải thiện độ chính xác của mô hình phân loại rác thải, ta có thể tối ưu quá trình tiền xử lý ảnh bằng cách giảm mức độ Gaussian Blur, áp dụng các bộ lọc làm nổi bật biên cạnh như Canny Edge Detection, và tăng kích thước ảnh lên  $128 \times 128$  thay vì  $64 \times 64$ ; đồng thời, kết hợp nhiều đặc trưng hơn như Local Binary Patterns (LBP) hoặc trích xuất đặc trưng từ mạng CNN thay vì chỉ sử dụng HOG; cải thiện mô hình học máy bằng cách thử nghiệm các tham số khác nhau của SVM (thay đổi C và kernel) hoặc sử dụng các mô hình mạnh hơn như CNN để học đặc trưng sâu hơn; và cuối cùng, bổ sung dữ liệu huấn luyện bằng cách thu thập thêm ảnh đa dạng về ánh sáng, góc nhìn, cũng như áp dụng kỹ thuật Augmentation (xoay, thay đổi độ sáng, crop) để giúp mô hình tổng quát hóa tốt hơn.

## 7. Kết luận

Mô hình SVM đạt độ chính xác 97% trong phân loại rác thải nhựa và kim loại, tuy nhiên vẫn có một số lỗi phân loại. Độ chính xác có thể cải thiện bằng cách tối ưu siêu tham số (**C, gamma, kernel**), mở rộng tập dữ liệu và áp dụng các phương pháp trích xuất đặc trưng tốt hơn như **SIFT, ORB**.

Việc ứng dụng AI vào phân loại rác giúp tự động hóa và tối ưu hóa quy trình xử lý rác thải. Hệ thống này có thể tích hợp vào **robot phân loại rác** hoặc **camera giám sát thông minh** để nhận diện và phân loại rác theo thời gian thực. Trong tương lai, việc kết hợp **Deep Learning (CNN, ViT)** và phát triển ứng dụng hỗ trợ nhận diện rác có thể giúp nâng cao hiệu quả thu gom và tái chế, góp phần bảo vệ môi trường.

## **8. Tài liệu tham khảo**

- [1] C. Cortes and V. Vapnik, "Support-Vector Networks," Machine Learning, 1995.
- [2] J. Platt, "Probabilistic Outputs for Support Vector Machines and Comparisons to Regularized Likelihood Methods," 1999.
- [3] Python Scikit-Learn Documentation: <https://scikit-learn.org/>